

Báo cáo kỹ thuật

Hệ thống phát hiện *hallucination* trong câu trả lời tiếng Việt

Kết hợp Qwen3 và Gemma3 — Ensemble (10 temperature mỗi model)

Tác giả: UIT_WhiteCow

Ngày: Ngày 7 tháng 10 năm 2025

Tóm tắt nội dung

Báo cáo này trình bày thiết kế và kết quả của pipeline phát hiện *hallucination* trong câu trả lời của các mô hình ngôn ngữ tiếng Việt. Giải pháp kết hợp hai mô hình chỉ dẫn (Qwen3 và Gemma3), cả hai đều được tinh chỉnh bằng LoRA và chạy inference trên dải 10 giá trị *temperature*. Các dự đoán từ nhiều mức *temperature* và hai mô hình được gộp bằng cơ chế ensemble nhằm đạt độ ổn định và độ chính xác cao hơn.

Mục lục

1	Mục tiêu	2
2	Kiến trúc và cách tiếp cận	2
2.1	Few-shot In-Context Learning	2
2.2	LoRA Fine-tuning	2
3	Mô hình và tham số kỹ thuật	2
3.1	Mô hình chính	2
3.2	Cấu hình LoRA	2
3.3	Quantization & Precision	2
4	Quy trình huấn luyện và inference	2
4.1	Pipeline huấn luyện	2
4.2	Pipeline inference	3
4.3	Sampling parameters (gợi ý)	3
5	Chiến lược ensemble	3
5.1	Majority voting	3
6	Kết luận	3
A	Phụ lục A: Cấu hình huấn luyện mẫu	3
B	Phụ lục B: Công cụ & tài nguyên	3

1 Mục tiêu

Mục tiêu của dự án là xây dựng một hệ thống tự động phân loại các câu trả lời của LLMs theo ba nhãn:

- **no** — Câu trả lời được hỗ trợ bởi ngữ cảnh (không bịa đặt).
- **intrinsic** — Câu trả lời mâu thuẫn hoặc xuyên tạc thông tin từ ngữ cảnh.
- **extrinsic** — Câu trả lời bổ sung thông tin mới không có trong ngữ cảnh.

2 Kiến trúc và cách tiếp cận

Hệ thống bao gồm hai lớp chính: *fine-tuning* (LoRA) và *inference + ensemble*. Thiết kế nhấn mạnh tính thực dụng: tiết kiệm tài nguyên, dễ triển khai và dễ mở rộng.

2.1 Few-shot In-Context Learning

Mỗi prompt chứa 5 ví dụ (few-shot). Các ví dụ đảm bảo đại diện cho ba nhãn và được lựa chọn theo seed cố định để tái lập.

2.2 LoRA Fine-tuning

Tinh chỉnh tham số hiệu quả bằng LoRA, chỉ cập nhật adapter trong attention và FFN layers. Cấu hình LoRA tiêu chuẩn sử dụng rank nhỏ để giảm bộ nhớ và thời gian huấn luyện.

3 Mô hình và tham số kỹ thuật

3.1 Mô hình chính

Mô hình	Kích thước	Ghi chú
Qwen3-4B-Instruct	4B tham số	Tối ưu cho ngữ cảnh tiếng Việt, instruction-tuned.
Gemma3-4B-Instruct	4B tham số	Mạnh về reasoning và diễn giải.

3.2 Cấu hình LoRA

- Rank (r): 32
- Alpha: 32
- Dropout: 0
- Modules: Q, K, V, O, gate, up, down

3.3 Quantization & Precision

- 4-bit quantization cho inference (giảm kích thước model còn 4GB).
- Merge thành 16-bit cho vLLM inference khi cần.
- Huấn luyện dùng bfloat16 (nếu phần cứng hỗ trợ).

4 Quy trình huấn luyện và inference

4.1 Pipeline huấn luyện

1. Nạp bản base cho Qwen3 và Gemma3 (đã quantized nếu cần).
2. Gắn LoRA adapters và chuẩn bị dữ liệu few-shot.

3. Fine-tune từng model độc lập bằng SFT (train_on_responses_only).
4. Lưu adapters và phiên bản merged để inference.

4.2 Pipeline inference

1. Với mỗi mô hình (Qwen3, Gemma3), chạy inference ở $T = \{t_1, t_2, \dots, t_{10}\}$ (10 mức temperature trải đều $0.0 \rightarrow 1.0$).
2. Ghi lại file kết quả riêng cho từng cặp (mô hình, temperature).
3. Gộp 20 file kết quả lại và áp dụng ensemble.

4.3 Sampling parameters (gợi ý)

- Temperature: 10 mức trong khoảng $[0.0, 1.0]$
- Top-p: 0.8
- Top-k: 5
- Max tokens: 64

5 Chiến lược ensemble

Đề xuất phương án ensemble chính:

5.1 Majority voting

Với mỗi mẫu, lấy nhãn mà xuất hiện nhiều nhất trong 20 kết quả. Nếu có hòa, dùng mức confidence trung bình làm tiebreaker.

6 Kết luận

Thiết kế kết hợp Qwen3 và Gemma3 với ensemble đa-temperature là một phương án thực tế để giảm hallucination và tăng tính ổn định của phân loại. Với LoRA và quantization, pipeline này phù hợp triển khai trên phần cứng thực tế (GPU 24GB) mà vẫn giữ hiệu quả cao.

A Phụ lục A: Cấu hình huấn luyện mẫu

```
--batch_size 4 --gradient_accumulation_steps 8
--learning_rate 5e-5 --weight_decay 0.01 --epochs 1
--max_seq_len 5000 --precision bfloat16
--lora_r 32 --lora_alpha 32 --lora_dropout 0
```

B Phụ lục B: Công cụ & tài nguyên

- Unsloth (LoRA training + quantization)
- vLLM (fast inference)
- TRL / SFTTrainer
- HuggingFace Transformers, PyTorch
- GPU: NVIDIA RTX 4090 (24GB VRAM) hoặc tương đương